

UNIVERSIDADE POSITIVO
ESCOLA DE TECNOLOGIA E INFORMAÇÃO
CURSO DE CIÊNCIA DA COMPUTAÇÃO

LUCAS GOMES DE OLIVEIRA

GRUPO 4

RELATÓRIO DE ATIVIDADE PRÁTICA:

CENÁRIO A: Inspeção de Frutas em Uma Central de Distribuição.

Relatório técnico apresentado como requisito de avaliação parcial da disciplina de **Visão Computacional**, do curso de Ciência da Computação da Universidade Positivo (UP).

Professor **José Jairo de Santana Silva**.

Curitiba

2026

1. Problema e dataset

O projeto aborda o cenário de inspeção visual automática de frutas em uma central de distribuição. O objetivo é simular um sistema capaz de separar maçãs aptas de maçãs fora de padrão, reduzindo a dependência de avaliação visual manual e tornando a triagem mais padronizada.

A tarefa foi simplificada para uma classificação binária entre duas classes: fresh, representando maçãs frescas, e rotten, representando maçãs podres ou deterioradas. O dataset utilizado foi o Fruits fresh and rotten for classification, disponível no Kaggle. Foram selecionadas apenas imagens de maçãs, originalmente nas classes freshapples e rottenapples.

- Classe fresh: 300 imagens.
- Classe rotten: 300 imagens.
- Total: 600 imagens balanceadas.
- Formato das imagens: arquivos PNG organizados em dataset/fresh e dataset/rotten.



Fresh - exemplo 1



Fresh - exemplo 2



Fresh - exemplo 3



Rotten - exemplo 1



Rotten - exemplo 2



Rotten - exemplo 3

Figura 1 - Exemplos de imagens reais usadas no dataset: maçãs frescas e podres.

2. Pipeline proposto

O pipeline segue a abordagem classica pedida no enunciado: aquisicao da imagem, segmentacao do objeto, extracao de features manuais, montagem da tabela X e do vetor y, treinamento de classificadores classicos e avaliacao final. A organizacao foi dividida em tres notebooks principais para manter cada etapa clara e reproduzivel.

Pipeline classico de Visao Computacional aplicado ao projeto



Figura 2 - Diagrama de blocos do pipeline implementado.

3. Segmentacao ou isolamento do objeto

A segmentacao tem como objetivo isolar a regiao da maca, evitando que pixels do fundo influenciem a extracao de features. Foram comparados dois metodos: Otsu no canal de saturacao HSV e Watershed baseado em marcadores.

O metodo Otsu/Saturacao apresentou melhor estabilidade para este dataset, pois as frutas tendem a ter saturacao maior que o fundo. Apos o threshold, sao aplicadas operacoes morfologicas para limpar a mascara e manter o maior contorno. O Watershed foi testado como alternativa, mas se mostrou mais sensivel a sombras, bordas escuras e regioes com contraste irregular.




Figura 3 - Comparacao entre Otsu/Saturacao e Watershed, com objeto isolado pelo metodo escolhido.

4. Features extraídas

Apos a segmentacao, cada imagem foi convertida em um vetor numerico de 39 features. As features foram escolhidas por sua relacao direta com sinais visuais de deterioracao, como mudanca de cor, manchas, textura irregular e deformacoes no contorno da fruta.

Familia	Features	Justificativa
Forma	area, perimeter, eccentricity, solidity, extent, circularity	Capturam tamanho, contorno e possiveis deformacoes.
Inerciais	7 momentos de Hu log-transformados	Descrevem a forma com robustez a escala e rotacao.
Cor	medias e desvios RGB/HSV	Representam escurecimento, brilho e variacao de cor.
Textura	GLCM e LBP	Capturam rugosidade, manchas e irregularidades da casca.

5. Selecao ou analise de features

A analise exploratoria incluiu boxplots por classe, medias por classe, comparacao visual de distribuicoes e importancia de variaveis do Random Forest. Essa etapa permite verificar se as features extraidas realmente ajudam a separar as classes.

As features relacionadas a cor e textura se mostraram especialmente relevantes, o que e coerente com o problema: macas deterioradas apresentam alteracoes visuais na superficie, como manchas, escurecimento, variacao de brilho e textura irregular.




Figura 4 - Boxplots de features selecionadas por classe.




Figura 5 - Top features segundo a importancia do Random Forest.

6. Classificadores usados

Foram treinados dois classificadores classicos baseados na tabela de features manuais: Random Forest e SVM. Ambos atendem ao requisito do projeto de comparar pelo menos dois modelos classicos.

Os dados foram divididos em treino, validacao e teste, de forma estratificada, na proporcao 60/20/20. A padronizacao com StandardScaler foi ajustada apenas no conjunto de treino, evitando vazamento de informacao. Os hiperparametros foram ajustados com GridSearchCV e validacao cruzada estratificada.

- Random Forest: modelo baseado em conjunto de arvores, com boa interpretabilidade por importancia de variaveis.
- SVM: classificador baseado em margem, avaliado com kernels linear e RBF apos padronizacao das features.

7. Resultados e metricas

A avaliacao final foi realizada apenas no conjunto de teste. As metricas usadas foram acuracia, precisao, recall e F1-score, alem da matriz de confusao e curva ROC para o caso binario.

Modelo	Acuracia	Precisao	Recall	F1-score
Random Forest	0.9750	0.9672	0.9833	0.9752
SVM	0.9750	0.9672	0.9833	0.9752

Os dois modelos apresentaram desempenho equivalente, com acuracia de 0,9750 e F1-score de 0,9752. O recall de 0,9833 indica boa capacidade de identificar a classe positiva, relevante em cenários de triagem onde deixar passar uma fruta podre pode ser mais custoso.




Figura 6 - Matrizes de confusao dos modelos avaliados.




Figura 7 - Curva ROC dos classificadores no problema binario.

8. Analise de erros

A analise de erros foi feita a partir das imagens do conjunto de teste classificadas incorretamente pelo melhor modelo. Essa etapa e importante porque mostra quais padroes visuais confundem o sistema e aponta limites do pipeline.

Os erros tendem a ocorrer em casos de fronteira: macas frescas com sombras, reflexos ou textura irregular, e macas podres com deterioracao menos evidente ou concentrada em regioes pequenas. Nessas situacoes, as features de cor e textura podem assumir valores intermediarios entre as duas classes.



Figura 8 - Exemplos de imagens classificadas incorretamente, com classe real e predita.

9. Conclusao

O projeto implementou com sucesso um pipeline classico de Visao Computacional para inspecao automatica de macas. As etapas obrigatorias foram contempladas: segmentacao, extracao de features, analise de features, classificacao com dois modelos classicos e avaliacao por metricas e graficos.

Como Random Forest e SVM apresentaram desempenho equivalente, a escolha recomendada para producao e o Random Forest. A justificativa principal e a interpretabilidade: o modelo fornece importancia de variaveis, facilitando explicar quais features influenciaram a decisao. Alem disso, tende a ser simples de treinar, monitorar e ajustar em um prototipo operacional.

Como limitacoes, o dataset possui imagens relativamente centralizadas e com fundo controlado. Em uma esteira real, variacoes de iluminacao, angulo, sombra, distancia da camera e fundo poderiam prejudicar a segmentacao. Como melhorias futuras, recomenda-se ampliar o dataset com imagens capturadas em ambiente real, testar segmentacoes mais robustas e comparar o pipeline classico com tecnicas avancadas, como transfer learning e metodos de explicabilidade.